

Reconocimiento de caracteres manuscritos Sitelen Pona: comparación de técnicas de entrenamiento para clasificación multiclase de bajos recursos

(Etapa 1)

Natalia Orozco Delgado
2024099161 / n.orozco.1@estudiantec.cr

Fernando Andrés González Robles
2024201276 / f.gonzalez.1@estudiantec.cr

Abstract—El reconocimiento de texto manuscrito (HTR) enfrenta retos particulares cuando se aplica a sistemas de escritura logográficos con un número elevado de clases y escasa disponibilidad de datos de entrenamiento por clase. Este trabajo aborda el reconocimiento de glifos aislados de *sitelen pona*, el sistema de escritura del idioma construido Toki Pona, donde cada uno de los aproximadamente 140 glifos representa una palabra completa del vocabulario. Dado el número de clases y la disponibilidad de apenas 100 a 150 muestras por clase, el problema se enmarca como un caso de clasificación multiclase extrema bajo condiciones *low-resource*, un escenario poco explorado en la literatura de reconocimiento de caracteres aislados. Se propone comparar el desempeño de distintas arquitecturas de clasificación (una CNN simple, una CNN con *transfer learning* convencional, y HCR-Net, una CNN *script-independent*) combinadas con distintas estrategias de aumento y expansión de datos (aumento tradicional, distorsión elástica, y expansión sintética mediante fuentes externas), con el fin de identificar la combinación que produce la mayor exactitud de clasificación. Hasta donde se ha revisado, no existe investigación previa sobre HTR aplicado a *sitelen pona*; este trabajo busca extender enfoques ya validados en otros escenarios de bajo recurso y muchas clases a un caso de idioma construido no abordado previamente en la literatura.

Index Terms—handwritten character recognition, extreme multiclass classification, deep learning, data augmentation, synthetic data generation

I. INTRODUCCIÓN

A. Contexto y relevancia del problema

El auge del *deep learning* en la última década ha transformado prácticamente todas las áreas de percepción por computadora, permitiendo que tareas antes dependientes de características diseñadas manualmente sean resueltas mediante representaciones aprendidas directamente de los datos. Especialmente, reconocimiento visual o auditivo son de los campos más beneficiados en esta corriente. Dentro de este contexto, el Reconocimiento de Texto Manuscrito (HTR) representa un gran área de investigación en el *deep learning*.

El HTR es una clase de Reconocimiento Óptico de Caracteres (OCR), utilizado ampliamente en la recuperación de material histórico, entrada de datos manuscritos o medidas de accesibilidad [1], entre otros. Aplicaciones relativamente novedosas como éstas traen consigo una serie de retos y limitaciones para conseguir los resultados esperados, entre ellos la escasa disponibilidad de grandes cantidades de datos

de entrenamiento [2], diferencia en tamaños o estilos de escritura, conexiones entre caracteres, cantidad de caracteres e incluso la similitud de su apariencia [3].

Un reto igualmente relevante en el campo es el de la clasificación multiclase extrema, presente cuando el número de categorías a distinguir crece considerablemente. Bengio et al. [4] señalan que, en estos escenarios, los métodos estándar de clasificación se vuelven intratables en tiempo y espacio, por lo que se han propuesto arquitecturas alternativas más eficientes ante conjuntos de clases numerosos. En el ámbito específico del reconocimiento de caracteres, HCR-Net [5] plantea una CNN *script-independent* validada en 40 conjuntos de datos de 14 idiomas distintos, mostrando que el *transfer learning* parcial permite generalizar razonablemente bien incluso cuando el número de clases es elevado, aunque su propio desempeño decae en escrituras con conjuntos de caracteres muy grandes.

Los obstáculos anteriormente citados se ven usualmente agravados en idiomas de bajo recurso o incluso construidos, los cuales presentan cantidades de datos más reducidas [6] y menos investigaciones específicas. Un caso comparable puede ser el de los manuscritos cifrados, donde igualmente contando con pocos ejemplos, se redujo significativamente la labor manual necesaria para el entrenamiento del modelo y se alcanzaron resultados sumamente positivos [6]. Se busca extender como enfoque a idiomas construidos modernos, más específicamente Toki Pona.

Toki Pona es uno de los idiomas construidos con mayor comunidad activa en el mundo, el cual fue creado por Sonja Lang en 2001 como una alternativa multipropósito y fácil de aprender. Actualmente, se ve presente en música, videos, *podcasts*, literatura, entre otras [7]. Su vocabulario oficial se compone de un núcleo reducido de palabras. En la edición original del libro se propusieron 120 palabras, este fue ampliado posteriormente por adiciones reconocidas por la comunidad. Sin embargo, reflejando la filosofía minimalista con la que fue diseñado, sigue sin alcanzar las 150 palabras oficiales [8]. Además, para su escritura fue desarrollado un sistema de escritura logográfico llamado *sitelen pona*, en el que cada uno de los glifos representa una palabra completa del vocabulario, en lugar de un fonema o letra como ocurre en los alfabetos convencionales [8] (Fig. 1).

El caso particular del *sitelen pona* lo vuelve un objeto de interés para el Reconocimiento de Texto Manuscrito; la elevada cantidad de glifos (del orden de 140 clases) lo convierte en un problema de clasificación multiclase extrema [4] y el hecho de que se tiene una limitada cantidad de datos de entrenamiento, impacta el planteamiento ya que se considera un caso *low-resource*.



Fig. 1. Repertorio de glifos de *sitelen pona*. Imagen: Wikimedia Commons, licencia CC BY-SA 4.0.

B. Pregunta de investigación

¿Cuál de las estrategias de entrenamiento evaluadas: una CNN simple entrenada de cero sin aumento de datos (baseline interno), una CNN simple con aumento de datos tradicional (rotación, shear, zoom y distorsión elástica), una CNN con transfer learning, y HCR-Net, una CNN script-independent basada en transfer learning parcial y aumentación geométrica [5]; produce la mayor exactitud de clasificación en un modelo de deep learning sobre los glifos de sitelen pona, dado un escenario de clasificación multiclase extrema con datos de entrenamiento limitados?

C. Hipótesis de trabajo

Se plantean dos hipótesis complementarias. Primero, se espera que HCR-Net [5], por su diseño *script-independent*, su entrenamiento en dos fases con transfer learning parcial de VGG16 y su validación en múltiples conjuntos de escritura “triviales” (pocas muestras por clase), supere a la CNN simple con o sin aumento de datos y a la CNN con transfer learning convencional. Segundo, siguiendo el mecanismo de balance observado por Wang et al. [9], se espera que la combinación *balanceada* de aumento de datos débil y expansión sintética (proporción real-sintético del orden de 2:1) supere a la aplicación independiente y agresiva de cualquiera de las dos estrategias.

D. Objetivos y contribución esperada

Objetivo general

Maximizar el rendimiento de un modelo de Reconocimiento de Texto Manuscrito para los glifos de *sitelen pona*, bajo las condiciones de clasificación multiclase extrema y disponibilidad limitada de datos de entrenamiento.

Objetivos específicos

- 1) Comparar el desempeño de distintas arquitecturas de clasificación (una CNN simple, una CNN con *transfer learning* convencional, y HCR-Net) sobre los glifos de *sitelen pona*, en un escenario de clasificación multiclase extrema.
- 2) Comparar distintas estrategias de aumento y expansión de datos (aumento tradicional, distorsión elástica, y expansión sintética con fuentes externas) para mitigar la escasez de datos de entrenamiento, evaluando su efecto sobre las arquitecturas anteriores.
- 3) Analizar el costo de esfuerzo manual asociado a cada estrategia de mitigación de bajo recurso evaluada, considerando el tiempo de preparación de datos, la necesidad de anotación adicional y la complejidad de implementación, con el fin de valorar no solo la exactitud alcanzada sino también su viabilidad práctica.

Se espera aportar evidencia empírica sobre qué combinación de arquitectura de clasificación y estrategia de mitigación de bajo recurso resulta más efectiva para un caso real de idioma construido, extendiendo enfoques ya explorados en otros escenarios a uno no abordado previamente en la literatura revisada.

E. Estructura del documento

El resto de este documento se organiza así: la Sección II presenta los trabajos relacionados en tres ejes; la Sección III identifica las brechas de la literatura; la Sección IV establece el baseline de literatura; la Sección V describe la metodología propuesta; la Sección VI presenta el análisis técnico específico del Track B; y la Sección VII discute consideraciones éticas preliminares.

II. TRABAJOS RELACIONADOS

Esta revisión se organiza en tres ejes: el problema/dominio (Eje A), las técnicas del track (Eje B), y el dataset/entorno (Eje C).

A. Eje A: El problema o dominio

Dada la clara necesidad de procesamiento de documentos para ser digitalizados como material computacional, surge el OCR como campo de estudio, contribuyendo a archivos digitales, recuperación de información [10] y accesibilidad [1]. Tradicionalmente, sistemas OCR se construían de manera que su proceso era dividido en dos etapas principales: detección (localización) y reconocimiento de texto (transcripción); lo que recargaba enormemente las etapas de pre y post procesamiento. Además, eran altamente imprecisas ante texto irregular o manuscrito. Todo ello mejoró significativamente con el surgimiento del *deep learning*, cuando las arquitecturas *deep learning* revolucionaron la manera en la que se procesaban los datos. El pre procesamiento explícito disminuyó, siendo sustituido por *data augmentation*; y posteriormente se perfeccionaron particularidades específicas con *fine-tuning* [10].

Considerando el auge actual referente a los LLMs es razonable valorar su inclusión en el área investigada, LLMs con capacidad de visión se posicionan en tareas OCR como buenas alternativas más dinámicas y popularizadas que los sistemas tradicionales. Por ello, Caravani et al. [10] se dedicaron a establecer una comparación tomando en cuenta las dimensiones operativas e inclusive subdividiendo los LLMs y motores OCR tradicionales en *open source* y comerciales. Para ello se evaluaron las cuatro categorías anteriormente mencionadas con dieciséis sistemas, se analizó su precisión, tiempo de procesamiento y costo. Los resultados fueron variados dependiendo del campo evaluado, específicamente para texto manuscrito relucen los LLMs multimodales por sobre los motores OCR especializados, los cuales tienen mejor desempeño en documentos impresos y estructurados. Sin embargo, como tema de exploración se menciona que en casos complejos sería beneficioso usar los LLMs como complemento a los motores clásicos, de manera que se pueda manejar el riesgo en entornos críticos [10].

El OCR como campo de investigación general puede subdividirse en Reconocimiento de Texto Impreso y Reconocimiento de Texto Manuscrito [10]. Cada uno de ellos posee particularidades únicas y aplicaciones distintas. El HTR tiene como principal reto la alta variabilidad en escrituras, y sus aplicaciones abarcan desde preservación de documentos antiguos hasta adaptaciones de accesibilidad [1]. Mientras que trabajos como el de Caravani et al. [10] evalúan sistemas a nivel de documento completo, para entender la evolución del campo de HTR se requiere examinar el problema en distintos niveles, desde caracteres individuales hasta documentos completos.

El HTR se ha apoyado en avances del Reconocimiento Automático de Voz (ASR), que presentan similitudes como datos secuenciales, con alta variabilidad y dependencia contextual. Garrido-Muñoz et al. [1] estudian los aportes principales del HTR, donde la evolución del *deep learning* y crecimiento en la variedad de *datasets* juegan un rol fundamental para incrementar su rendimiento. Se enfocan principalmente en el proceso de transcripción, donde se presentan dos tipos

principales de granularidad. El más simple es el *up to line-level*, que trabaja por palabras o incluso líneas, mientras que el reconocimiento de párrafos o documentos completos, se clasifica como *beyond line-level*. Con el aumento de capacidad computacional disponible, la investigación del HTR busca métodos *end-to-end* que puedan sobrepasar al *up to line-level* [1].

Una vez llegado al reconocimiento más allá de líneas, emerge una nueva problemática que es el Orden de Lectura (RO), de esto depende mantener el sentido e intención del texto. Cada sistema de escritura tiene sus propias reglas de lectura. El número de direcciones de lectura necesarias aumenta con la complejidad del documento. A nivel de línea o palabra, el RO sigue una única dirección, determinada por el sistema de escritura; por ejemplo, de izquierda a derecha en textos de origen latino y de arriba a abajo en chino o japonés. A nivel de párrafos, se introduce una nueva dirección perpendicular a la anterior, la cual permite saltar entre líneas. Una tercera dimensión existe en documentos con bloques independientes e irregularmente posicionados [1].

Garrido-Muñoz et al. [1] también delimitan el HTR de sus campos relacionados. Lo distinguen del HTR *online* (reconocimiento en tiempo real del trazo, presión y orden de los movimientos), del *Scene Text Recognition* (texto en escenas naturales con ruido entorno), *Keyword Spotting* (localización de palabras específicas), *Layout Analysis* (segmentación estructural de secciones del documento), *Document Understanding* (interpretación de información) y *Handwritten Text Generation* (producción de imágenes realistas de texto escrito a mano desde contenido digital).

Los autores concluyen que la ausencia de un marco de comparación unificado se refleja en tres problemas principales: la dependencia a un conjunto reducido de *datasets*, inconsistencias en la tokenización de conjuntos de caracteres y reproducibilidad limitada. Además, señalan que la mayoría de los sistemas se evalúan únicamente en particiones del mismo *dataset*, lo que sesga la evaluación hacia ciertos idiomas y estilos de escritura; por esa razón, se deben diversificar las evaluaciones para medir de forma más realista la capacidad de generalización de los modelos. Identifican además, que muchos sistemas dependen de grandes cantidades de datos sintéticos, lo que dificulta su adaptación cuando los datos reales disponibles son limitados [1].

Previamente en [1] se excluyó el reconocimiento a nivel de caracteres debido a una literatura de clasificación general ya robusta. El tema se aborda más a profundidad por Rahman et al. [3], donde se realiza un reconocimiento de caracteres bengalíes escritos a mano utilizando una Red Neuronal Convolutiva (CNN). Contaron con veinte mil muestras variadas, divididas en cincuenta clases (en ciertos casos, con diferencias mínimas entre ellas). El método consistió en normalizar las imágenes de los caracteres escritos y luego emplear la CNN como clasificador. Se utiliza precisamente porque a diferencia de los métodos tradicionales que primero extraen las características de la imagen de forma manual y luego se clasifican con métodos de Perceptrón Multicapa (MLP), la CNN se

encarga de extraerlas de la imagen ya normalizada con su operación convolucional [3].

La alternativa a las características diseñadas a mano no siempre fue el *deep learning*: Chacko et al. [11] proponen un clasificador de caracteres Malayalam basado en la combinación de un descriptor de energía wavelet (WEF) y una *extreme learning machine* (ELM), una red de una capa oculta cuyos pesos de entrada se fijan aleatoriamente y cuyos pesos de salida se resuelven analíticamente. Con 9000 muestras de 30 clases recolectadas de 300 personas alcanzaron 95.59% de exactitud, con un entrenamiento notablemente rápido (del orden de minutos en CPU de la época); sin embargo, el enfoque depende de un descriptor geométrico predefinido y decae ante escritura con inclinación (*angled*), lo que contrasta con el aprendizaje *end-to-end* de las CNN.

B. Eje B: Las técnicas del track (Track B)

El tener *datasets* con material limitado es un problema con diferentes propuestas investigadas, con el propósito de entrenar correctamente al modelo con lo que se tiene. Ly et al. [12] proponen un modelo *end-to-end* para reconocimiento de texto japonés manuscrito donde se aplica la técnica de distorsión elástica local y global. El HTR para japonés es complicado por el hecho que tienen un conjunto de caracteres de un tamaño considerable, en este caso se aplicó la distorsión local a cada carácter previo al proceso de concatenación. La diferencia entre distorsiones globales y locales radica en el momento de su aplicación, la distorsión local es aplicada previo a la concatenación a la línea (incluyendo shear, rotación, escala y traslación aleatorios) mientras que la global es aplicada después, en la línea completa (mediante rotación y escala adicionales). El proceso elevó la efectividad del modelo de 96.35% a 98.05% y se muestra efectivo para el nivel necesitado en casos similares a los glifos de *Sitelen Pona*. Cabe destacar que esta técnica parte de patrones de caracteres reales ya existentes, introduciendo variaciones sobre datos disponibles en lugar de generar trazos completamente nuevos.

Si bien muchos estudios parten de la generación de datos sintéticos, Wang et al. [9] valoran la verdadera mejora en el rendimiento de los modelos al incluirlos. En ciertas ocasiones, los aumentos son mínimos, por lo que se buscó una proporción ideal para maximizar la eficiencia real. Se rigen por el teorema de la inflación, donde la distancia entre las distribuciones real y combinada depende de la calidad de la generación sintética y de la proporción entre los datos reales y artificiales. Como era de esperarse, es determinantemente significativa la calidad del generador. De las conclusiones más relevantes es el balance que se debe tener con la *augmentation* y expansión de datos, tienen una relación inversa, por lo que no se deben maximizar ambas a la vez. De ello, surge la estrategia de SmartExp con una proporción de real a sintético de 2:1 y una *augmentation* débil, de tan solo 0.1. Se presentan mejoras consistentes en cinco arquitecturas distintas y sobre tres diferentes *datasets*. Tomar en cuenta el ajuste de las variables estudiadas maximiza la eficiencia del modelo sin requerir esfuerzo computacional adicional. Fue trabajado bajo el generador VATr; sin embargo,

resultan aplicables los ajustes expansión y *augmentation* para las transformaciones a realizar en *datasets* limitados.

El reconocimiento de caracteres sobre escrituras de muchos símbolos no se limita a arquitecturas profundas: el seminario Dagstuhl sobre clasificación extrema [4] formaliza el problema como clasificación multi-etiqueta/multiclase con millones de etiquetas posibles y señala que los métodos estándar de *one-vs-all* u *one-vs-one* se vuelven intratables en tiempo y espacio. En esa línea, Yen et al. [13] proponen PD-Sparse, un método lineal con penalización ℓ_1 que explota la escasez tanto primal como dual para reducir la complejidad a sublineal en el número de clases; no obstante, su supuesto de un espacio de características suficientemente rico para separar clases y su naturaleza lineal lo hacen poco adecuado para la variabilidad no lineal de los glifos manuscritos, donde la CNN extrae las representaciones directamente de los píxeles [3].

Otra vía para conjuntos limitados es el *transfer learning*. Aarif y Poruran [14] adaptan variantes de AlexNet y GoogleNet pre-entrenadas en ImageNet mediante *fine-tuning* de las capas finales (y congelamiento de las iniciales) para el reconocimiento de caracteres manuscritos urdu sobre el dataset IFHCDB, alcanzando 96.3% de éxito medio con OCR-AlexNet; como verificación de generalización construyeron un dataset adicional renderizado con distintas fuentes y tamaños, de modo que el modelo no solo se evaluara con el estilo de escritura del dataset original. En la misma dirección, HCR-Net [5] propone la primera CNN *script-independent* para HCR offline: inicializa parcialmente sus capas bajas y medias con pesos pre-entrenados de VGG16 (hasta `block4_conv2`), los congela en una primera fase de entrenamiento y reentrena todas las capas en una segunda fase. Gracias al transfer learning parcial y a la aumentación de imágenes, HCR-Net converge en pocas épocas, reduce 34% los parámetros entrenables frente a VGG16 y logra hasta un 99% de su desempeño final en la primera época, incluso en conjuntos “triviales” de pocas muestras por clase; fue validado en 40 datasets de 14 idiomas, estableciendo 26 nuevos benchmarks. Su segunda fase resulta costosa y su rendimiento decae en lenguas con conjuntos de caracteres muy grandes, como el que aquí se plantea.

En cuanto a las transformaciones de datos, la revisión de Alomar et al. [15] clasifica la aumentación según su propósito (tamaño vs. diversidad) y reporta que, para tareas de pequeño tamaño y escala de grises, las transformaciones geométricas superan a las de color; además proponen la *random local rotation* (RLR), una estrategia sin parámetros que rota regiones circulares locales para evitar los bordes irregulares que introduce la rotación global tradicional, y que en sus experimentos superó consistentemente a la rotación clásica en clasificación y segmentación.

Por otra parte, la cantidad de datos no es el único factor limitante en el rendimiento de un modelo, sino también la variedad de los datos que se aborde. Chang et al. [2] establecen que los datos de escritura pueden evaluarse desde la dimensión de contenido o de estilo. Ambos se combinan para lograr cubrir todo el espacio de la matriz de datos (espacio combinatorio de contenido y estilo). Para ello, proponen un

modelo generativo controlable, el cual es capaz de generar los datos específicos que falten, en lugar de generar al azar. En el caso de texto manuscrito, puede verse como un estilo subrepresentado la cursiva y contenido subrepresentado las direcciones de correo electrónico. Su investigación se basó en HTR *online*, sin embargo, el principio metodológico de buscar grupos de datos con baja presencia o representación es aplicable a múltiples entornos, incluyendo el reconocimiento *offline* de caracteres aislados.

Para manuscritos de bajo recurso, como alfabetos crifrados o antiguos, no se cuenta con modelos de lenguaje aptos para el entrenamiento y la anotación manual de todos los símbolos sería sumamente costoso en términos de tiempo y recurso humano. De esta manera, Souibgui et al. [6] proponen un *pipeline* de tres partes principales. La primera es el pre entrenamiento con símbolos genéricos de un *dataset* de alfabetos variados. Posteriormente, se utiliza la técnica de *few-shot*, donde dados escasos símbolos de referencia, se buscan coincidencias mediante un mecanismo de atención y matriz de similitud. Por último, se utiliza un mecanismo de entrenamiento de pseudo-etiquetado progresivo, de manera que el modelo se continúa entrenando y asignando etiquetas a los símbolos con mayor confianza, de manera que se expande el conocimiento sin trabajo manual adicional. Se obtuvieron resultados comparables con etiquetado manual completo sin la necesidad de tiempos elevados de anotación manual, aunque se ve disminuido su rendimiento con símbolos conectados entre sí.

C. Eje C: El dataset o entorno

Debido a la escasa cantidad de estudios sobre el *dataset* seleccionado, se evalúan casos comparables como marco de referencia. Rahman et al. [3] utilizan un *dataset* de alfabeto bengalí, el cual no es latino y posee símbolos distinguibles por rasgos mínimos, similar al Sitelen Pona. Tiene un tamaño moderado de datos, cuenta con veinte mil imágenes divididas en cincuenta clases obtenidas en una recolección propia. Su protocolo experimental dividió el conjunto en 17500 imágenes de entrenamiento (350 por clase), 2500 de prueba (50 por clase) para así evaluar mediante la métrica de precisión del modelo. Su resultado utilizando un CNN simple fue de 85.96% de precisión. Como limitación se reporta la confusión de caracteres similares incluso con aproximadamente cuatrocientas muestras por clase.

De manera similar, Souibgui et al. [6] realizan HTR para alfabetos cifrados o en desuso (Borg, Copiale y Codex Runicus); similar al Sitelen Pona, no se cuenta con literatura previa ni modelos de lenguaje de apoyo. Los tamaños de estos *datasets* son considerablemente menores al del Sitelen Pona: entre 24 y 78 clases, con un total de 1,913 a 7,197 símbolos anotados según el manuscrito. Compararon distintos escenarios de supervisión, desde métodos no supervisados hasta el etiquetado manual completo, pasando por su propio método de *few-shot* con solo 5 ejemplos por símbolo, evaluando el desempeño mediante la Tasa de Error de Símbolo. Su método alcanzó un SER de 0.09 a 0.24 según el manuscrito, resultado comparable

al obtenido con etiquetado manual completo (0.05 a 0.21). Como limitación, reportan una disminución en el rendimiento para alfabetos con símbolos conectados o solapados entre sí.

Con un propósito comparable, Chacko et al. [11] recolectaron 9000 imágenes Malayalam de 30 clases escritas por 300 personas diferentes (2:1 entrenamiento/prueba), un esquema de varios escritores que también es habitual en HCR-Net [5], cuyos benchmarks de Gurmukhi incluyen desde un único escritor con 100 muestras por clase (HWRGurmukhi_1.1, 99.31% de exactitud) hasta 100 escritores con una muestra por clase (HWRGurmukhi_1.3, 96.53%), una condición aún más restrictiva por escritor que la de nuestro dataset.

El caso del urdu de Aarif y Poruran [14] es directamente relevante por dos razones: utilizan el dataset IFHCDB (uno de los más grandes para escritura cursiva) y además construyen un dataset auxiliar renderizando las mismas clases con distintas fuentes y tamaños para medir la generalización de OCR-AlexNet, mostrando que la exactitud depende sensiblemente del número de imágenes, de su resolución y de los pesos de la red. Este mismo procedimiento (renderizado con fuentes) es el que aquí se contempla como expansión sintética.

Finalmente, los idiomas de bajo recurso con sistemas de escritura complejos y fondos poco controlados, como el mongol, han motivado pipelines híbridos: Qi et al. [16] combinan Mask-RCNN para la detección de regiones de texto, *prompt tuning* de un modelo pre-entrenado y un post-procesador RoBERTa para alcanzar 91.2% de exactitud de carácter en el dataset MLWS2021; el resultado ilustra que, incluso con arquitecturas modernas, el reconocimiento de escrituras de bajo recurso sigue siendo un reto abierto, y que la integración de módulos especializados (detección, reconocimiento, corrección) es una vía activa de investigación.

D. Tabla comparativa de trabajos relacionados

La Tabla I resume los trabajos revisados en este estado del arte, según el protocolo, la métrica y el resultado reportado por cada autor.

III. BRECHAS IDENTIFICADAS

Con base en los ejes revisados, se identifica un conjunto de carencias concretas:

- 1) **Ausencia de literatura sobre HTR offline de glifos logográficos de idiomas construidos.** Los trabajos de HCR aislado se concentran en alfabetos naturales (bengalí, urdu, Malayalam, japonés, mongol) y las revisiones existentes excluyen explícitamente el nivel de carácter aislado [1]. No se encontró ningún estudio sobre *sitelen pona*. Este proyecto la aborda en su totalidad, al establecer el primer benchmark de clasificación de glifos de *sitelen pona*.
- 2) **Clasificación multiclase extrema con datos limitados a nivel de carácter aislado.** La literatura de clasificación extrema se desarrolla sobre datos lineales de alta dimensionalidad ([4], [13]) o sobre conjuntos con abundante datos (japonés [12]); los datasets de HCR aislado con muchos glifos y pocas muestras por

clase son escasos. HCR-Net reconoce explícitamente que su rendimiento decae en lenguas con conjuntos de caracteres muy grandes [5]. El proyecto la aborda parcialmente: se trabajan ~ 140 clases (mayor que las 30–56 típicas, menor que los millares del japonés) con < 150 muestras por clase, y se mide el efecto de la escala.

- 3) **Variantes alográficas y alta variabilidad intra-clase.** Caracteres como *sewi* presentan alomorfos sin rasgos visuales compartidos (glifo histórico vs. moderno), y *jaki* es por diseño un “garabato” con varianza intra-clase prácticamente no acotada; ningún trabajo revisado modela estas situaciones en HCR. El proyecto la aborda mediante subclases internas que se fusionan programáticamente en la salida y mediante análisis específico de la matriz de confusión.
- 4) **Brecha de distribución entre expansión sintética y escritura real (domain gap).** La mayoría de los sistemas depende de grandes cantidades de datos sintéticos, cuya adaptación a los datos reales disponibles no está resuelta [1]; incluso generadores de alta calidad requieren proporciones y niveles de aumentación cuidadosos [9]. El proyecto la aborda parcialmente, aplicando principios de balance de [9] y aumentando los renderizados con distorsiones no lineales.
- 5) **Síntesis dirigida por contenido/estilo no explorada en HCR offline aislado.** El principio de generación dirigida a huecos específicos de contenido y estilo, propuesto por [2], se ha validado solo en HTR *online* a nivel de secuencia; su aplicación a generación offline de caracteres aislados permanece sin explorar. El proyecto la aborda parcialmente al aplicar expansión sintética con fuentes externas, aunque sin implementar el modelo generativo controlable completo.
- 6) **Brechas fuera del alcance.** No se aborda la transcripción a nivel de línea o documento (lectura de líneas completas, *beyond line-level*), la generación sintética por modelos generativos (GAN/HTG) como SLOGAN o VATr, la clasificación multi-etiqueta, ni la competencia con LLMs multimodales evaluada por Caravani et al. [10]; el alcance se restringe a caracteres aislados *offline*, monoclasa.

IV. BASELINE DE LITERATURA

No existe un resultado publicado directamente sobre *sitelen pona*; el baseline debe construirse a partir de los datasets análogos del Eje C (Sección II-C). El mejor resultado publicable comparable es el de HCR-Net [5]: sobre datasets aislados de escrituras no latinas con una o pocas muestras por clase por escritor alcanza, por ejemplo, 99.31% (HWRGurmukhi_1.1: 35 clases, un escritor, 100 muestras/clase) y 96.53% (HWRGurmukhi_1.3: 35 clases, 100 escritores, una muestra/clase por escritor), estableciendo a su vez 26 benchmarks en 40 datasets. Como referencia de una CNN simple sin aumentación, la de Rahman et al. [3] reporta 85.96% sobre 50 clases con 400 muestras por clase. Por lo tanto, se declara como baseline

de literatura a HCR-Net, reproducido sobre nuestro propio dataset, y como cota inferior de referencia la exactitud de la CNN simple [3] y del descriptor geométrico de [11] (95.59% sobre 30 clases). Como referencia adicional para escenarios de alfabetos sin literatura previa, Souibgui et al. [6] reportan un SER de 0.09 a 0.24 sobre alfabetos cifrados y rúnicos con muy pocos ejemplos por símbolo, aunque la métrica no es directamente comparable con la exactitud reportada por los demás baselines.

Debe señalarse explícitamente que una comparación numérica directa con estos valores no sería justa, por diferencias de protocolo: (i) las clases son distintas (30–56 en los datasets análogos vs. ~ 140 en *sitelen pona*); (ii) el número de muestras por clase es mayor en los datasets análogos (100–400 vs. ~ 100 –150); (iii) la partición es de 80:20 distribución aleatoria en [5], mientras que aquí se planea una partición estratificada por clase, sin disjunción por escritor debido a que el *dataset* público utilizado no incluye dicho metadato; y (iv) la resolución de entrada (32×32 en HCR-Net) y las condiciones de ruido del fondo no coinciden. Por ello, la comparación justa se establece contra los baselines internos de la Sección V, entrenados con la misma partición, preprocesamiento y métrica.

V. METODOLOGÍA PROPUESTA

A. Formalización del problema

Sea $\mathcal{X} \subset \mathbb{R}^{h \times w}$ el espacio de imágenes de glifos aislados (escala de grises o binarias) y $\mathcal{Y} = \{1, \dots, C\}$ el conjunto de etiquetas, con $C \approx 140$. Disponemos de un conjunto de entrenamiento $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ con N pequeño relativo a C (es decir, $\min_c n_c \ll N/C$), donde n_c es el número de ejemplos de la clase c ; este desbalance entre C y la disponibilidad por clase define el régimen de clasificación multiclase extrema [4]. Se busca una hipótesis $f_\theta : \mathcal{X} \rightarrow \Delta^C$ que minimice la pérdida de entropía cruzada

$$\min_{\theta} \frac{1}{N} \sum_{i=1}^N -\log f_\theta(x_i)[y_i], \quad (1)$$

sujeta a las estrategias de mitigación de bajo recurso (aumentación y expansión sintética) descritas abajo. La exactitud *top-1* se define como Acc_k con $k = 1$, generalizándose a *top-k* para caracteres visualmente similares.

B. Pipeline previsto

El flujo propuesto es: (i) dataset base recopilado por los autores (~ 100 –150 ejemplos por cada uno de los ~ 140 glifos, en PNG y escala de grises); (ii) preprocesamiento (recorte por *bounding box*, binarización opcional, redimensionamiento normalizado); (iii) aumento tradicional (rotación, shear, zoom, traslación y distorsión elástica) y expansión sintética (renderizado con fuentes externas de *sitelen pona* en proporción balanceada respecto a los datos reales); (iv) partición estratificada (por clase y, cuando sea posible, disjunta por escritor); (v) entrenamiento de las arquitecturas candidatas; (vi) evaluación con las métricas definidas en el protocolo experimental. Todo el pipeline se implementará en Python (TensorFlow/Keras), siguiendo la implementación pública de HCR-Net.

C. Protocolo experimental

El conjunto se particionará en 70% entrenamiento/15% validación/15% prueba mediante muestreo estratificado por clase; cuando se cuente con la identidad del escritor, las particiones se harán disjuntas por escritor para evitar fuga de estilo y medir la generalización realista, como recomienda [1]; el *dataset* público utilizado en este proyecto no incluye dicha información, por lo que se aplicará una partición estratificada por clase. Cada configuración se entrenará 5 veces y se reportará la media y desviación estándar de las métricas sobre la partición de prueba, reportando la exactitud de la última época (no la mejor) como recomiendan [5].

Las métricas elegidas son: (i) exactitud *top-1*, primaria y suficiente cuando las clases están balanceadas [5]; (ii) exactitud *top-3/top-5*, útil en problemas de $C \approx 140$ clases con pares visualmente similares; (iii) *macro-F1*, para no sesgar la medida ante las diferencias de n_c entre glifos frecuentes y raros; y (iv) la matriz de confusión, para identificar los pares de glifos confundibles (e.g., *sewi* vs. su alomorfo). Esta elección sigue la práctica de [10] (múltiples métricas a nivel de carácter y palabra: CA, NED, FCA) y de [9] (WAR/NED).

D. Plan de baselines

Además del baseline de literatura (HCR-Net, Sección IV), se implementarán los siguientes baselines internos, entrenados con la misma partición, preprocesamiento y métricas:

- 1) **CNN simple sin aumento de datos** (entrenada de cero, sin transfer learning), como cota inferior análoga a la de Rahman et al. [3].
- 2) **CNN simple con aumento de datos tradicional** (rotación, shear, zoom, traslación y distorsión elástica), para aislar el efecto del aumento sobre la misma arquitectura.
- 3) **CNN con transfer learning** (fine-tuning de una red pre-entrenada en ImageNet), como ha hecho [14] para urdu.
- 4) **HCR-Net** [5] como baseline de literatura y técnica principal.

Con este diseño factorial se puede descomponer la contribución de cada técnica (arquitectura, transfer learning, aumentación) al desempeño final.

E. Riesgos identificados y mitigación

A continuación se listan los riesgos técnicos del proyecto y sus mitigaciones:

- 1) **Domain gap por expansión sintética.** El renderizado con fuentes introduce una brecha de distribución con la escritura real [1]. *Mitigación:* aplicar los principios de balance de [9] (proporción real sintético del orden de 2:1 y aumentación débil), y aplicar distorsiones elásticas y ruido sobre los renderizados para acercar el dominio sintético al manuscrito, como en [6], [12].
- 2) **Variantes alográficas (e.g., *sewi*).** Un mismo glifo puede tener dos variantes sin rasgos compartidos; una única clase forzaría al clasificador a un espacio de representación multimodal. *Mitigación:* modelar internamente cada variante como una subclase separada en

la cabeza de clasificación, y fusionar programáticamente las subclases en una única clase a la salida (mapeo de subclase a etiqueta). Esto permite al clasificador separar los modos visuales sin violar la semántica del problema.

- 3) **Alta varianza intra-clase de *jaki*.** Por definición, *jaki* es “cualquier garabato”, por lo que su varianza no está acotada y satura la clase. *Mitigación:* aplicar una aumentación específica y reforzada sobre esta clase, monitorear su contribución a la matriz de confusión, y evaluar variantes con espacio de rechazo (clasificación *open-set*) para separar ejemplos ambiguos.
- 4) **Costo computacional del entrenamiento.** Entrenar múltiples arquitecturas sobre ~ 140 clases y un dataset expandido es pesado. *Mitigación:* usar arquitecturas con transfer learning parcial (HCR-Net reduce 34% los parámetros entrenables frente a VGG16 y converge en pocas épocas [5]), imágenes de 32×32 , *early stopping* basado en la partición de validación, y presupuestar el cómputo en GPU (Sección VI).

VI. ANÁLISIS TÉCNICO ESPECÍFICO – TRACK B

A. Análisis del conjunto de imágenes

El *dataset* es propio y consiste en glifos aislados de *sitelen pona* en formato PNG, en escala de grises (potencialmente binarios) sobre fondo limpio. Se estiman entre ~ 100 y ~ 150 muestras por cada uno de los ~ 140 glifos, es decir, del orden de 10^4 imágenes en el conjunto base. La resolución de las imágenes no es fija a priori y será normalizada en el preprocesamiento. Como sesgo documentado, se anticipa que las muestras provienen de un número reducido de escritores (posiblemente muy pocas personas), lo que concentra el estilo de escritura y puede inflar el rendimiento si no se controla adecuadamente; si se contara con la identidad del escritor, se aplicaría una partición disjunta para evitar este efecto, aunque el *dataset* público utilizado no incluye dicho metadato, por lo que la validación se basa en partición estratificada por clase y en el análisis de la distribución de ejemplos por clase.

B. Estrategias de data augmentation

Con base en la literatura revisada (Sección II-B), se aplicarán las siguientes técnicas:

- **Rotación** en $\pm 10^\circ$, **shear** de 0.5, **zoom** de 0.05 y **traslación** horizontal/vertical de 0.05, siguiendo la configuración validada de HCR-Net [5]. Se evaluará la alternativa *random local rotation* (RLR) de [15] para evitar los bordes irregulares de la rotación global. Como referencia, véase (Fig. 2).
- **Distorsión elástica** local (sobre cada glifo) y global (sobre el conjunto aumentado), que en japonés elevó la exactitud de 96.35% a 98.05% [12]; sobre imágenes de escala de grises y trazo fino, las transformaciones geométricas superan a las de color [15]. Como referencia, véase (Fig. 2).
- **Expansión sintética con fuentes externas** de *sitelen pona*, renderizando cada glifo en distintos tamaños y pesos, como hicieron [14] para urdu y [6] para alfabetos




Fig. 2. Transformaciones de aumento de datos aplicadas sobre un glifo del *dataset* propio: rotación, *shear*, *zoom*, traslación y distorsión elástica [12].

sintéticos; se balanceará la proporción real-sintético y la intensidad de aumentación siguiendo [9].

- **Exclusión explícita del volteo horizontal.** En sistemas logográficos el volteo puede invertir la direccionalidad del glifo y cambiar su significado, por lo que se omite, al igual que el volteo vertical, siguiendo las advertencias de [5].
- **Generación dirigida por contenido/estilo subrepresentado.** Siguiendo el principio metodológico de [2], se identificarán qué glifos o variantes están subrepresentados en el *dataset* base, priorizando la expansión sintética específicamente hacia esos huecos en lugar de aumentar todas las clases por igual.

C. Preprocesamiento

El preprocesamiento contempla: (i) recorte por *bounding box* del glifo para eliminar márgenes; (ii) binarización opcional (umbral Otsu) si la imagen presenta ruido de fondo; (iii) redimensionamiento a 32×32 píxeles conservando la proporción y con *padding*, para reproducir fielmente la entrada de HCR-Net [5] y mantener la memoria acotada; y, opcionalmente, (iv) normalización del contraste. Todo el conjunto queda entonces en el dominio $\mathcal{X} \subset [0, 1]^{32 \times 32}$ de la Ec. (1).

D. Consideraciones de hardware y memoria

El entrenamiento se realizará en una GPU de Google Colab (p. ej. la Tesla T4 de 16 GB de VRAM; opcionalmente una T4/A100 con plan de pago) y, de ser necesario, en la memoria RAM local. El conjunto base (del orden de 10^4 imágenes de 32×32 en 8 bits, ~ 1 KB cada una) ocupa del orden de unos decenas de MB; el conjunto expandido, estimado en el orden de 10^4 – 10^5 imágenes según el factor de aumentación elegido, se mantiene en el rango de cientos de MB y cabe en la memoria de trabajo de Colab. En cuanto al tiempo: HCR-Net converge en pocas épocas (la fase 1 alcanza $\sim 99\%$ de su desempeño en la primera época [5]; p. ej., 30+20 épocas sin aumentación y 10+50 con aumentación), por lo que, con GPU T4, se estima un tiempo de entrenamiento del orden de 1–3 horas por configuración; con 4 arquitecturas $\times$ 5 corridas, el presupuesto total de cómputo se estima en 1–2 días de GPU, factible en la cuota gratuita de Colab.

VII. CONSIDERACIONES ÉTICAS PRELIMINARES

El *dataset* empleado corresponde a un repositorio público de muestras manuscritas de *sitelen pona*, recolectado por la comunidad mediante envíos web anónimos y liberado bajo licencia de dominio público (CC0 1.0 Universal). Al tratarse de contribuciones ya publicadas voluntariamente bajo esta licencia, no se requiere solicitar consentimiento adicional para su uso en este proyecto. No obstante, dado que la caligrafía puede considerarse un rasgo biométrico [5], se verificó que las muestras no incluyan metadatos que permitan identificar a las personas contribuyentes, y se documentará explícitamente la fuente y los términos de la licencia en el repositorio del proyecto.

En cuanto a las fuentes externas de *sitelen pona* que se emplearán para la expansión sintética, se revisará la licencia de cada fuente antes de su uso: muchas son de acceso abierto bajo licencias *Creative Commons* u equivalentes, pero otras pueden tener restricciones de atribución o ser propietarias. Se documentará el cumplimiento de cada licencia (incluyendo la atribución requerida en el repositorio del proyecto) y se excluirán las fuentes cuyo uso con fines de entrenamiento no esté permitido explícitamente. Finalmente, el uso de modelos de lenguaje en la redacción de este documento se limita a asistencia de escritura, y no se emplean datos personales ni contenido generado como datos de entrenamiento.

REFERENCES

- [1] C. Garrido-Munoz, A. Rios-Vila, and J. Calvo-Zaragoza, “Handwritten Text Recognition: A Survey,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 48, no. 4, pp. 4367–4387, Apr. 2026. [Online]. Available: <https://ieeexplore.ieee.org/document/11303599/>
- [2] J.-H. R. Chang, M. Bresler, Y. Chherawala, A. Delaye, T. Deselaers, R. Dixon, and O. Tuzel, “Data Incubation — Synthesizing Missing Data for Handwriting Recognition,” in *ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Singapore, Singapore: IEEE, May 2022, pp. 4188–4192. [Online]. Available: <https://ieeexplore.ieee.org/document/9746229/>
- [3] Dept. of Computer Science and Engineering Khulna University of Engineering & Technology Khulna, Bangladesh, M. M. Rahman, M. A. H. Akhand, S. Islam, P. Chandra Shill, and M. M. Hafizur Rahman, “Bangla Handwritten Character Recognition using Convolutional Neural Network,” *International Journal of Image, Graphics and Signal Processing*, vol. 7, no. 8, pp. 42–49, Jul. 2015. [Online]. Available: <http://www.mecs-press.org/ijigsp/ijigsp-v7-n8/v7n8-5.html>
- [4] S. Bengio, K. Dembczyński, T. Joachims, M. Kloft, and M. Varma, “Extreme classification (dagstuhl seminar 18291),” in *Dagstuhl Reports*, vol. 8, no. 7. Schloss Dagstuhl—Leibniz-Zentrum für Informatik, 2019, pp. 62–80.

- [5] V. K. Chauhan, S. Singh, and A. Sharma, "Hcr-net: A deep learning based script independent handwritten character recognition network," *Multimedia Tools and Applications*, 2024, preprint disponible en arXiv:2108.06663.
- [6] M. A. Souibgui, A. Fornés, Y. Kessentini, and B. Megyesi, "Few shots are all you need: A progressive learning approach for low resource handwritten text recognition," *Pattern Recognition Letters*, vol. 160, pp. 43–49, Aug. 2022. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S016786552200191X>
- [7] S. Lang, "Toki pona (official site)," 2026, accessed: 2026-09-01. [Online]. Available: <https://tokipona.org>
- [8] "lipu linku: An interactive dictionary for toki pona," 2026, accessed: 2026-09-01. [Online]. Available: <https://linku.la>
- [9] Y. Wang, H. Wei, and S. Sun, "SmartExp: An Adaptive Data Expansion Strategy for Improving Handwritten Text Recognition," in *ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Hyderabad, India: IEEE, Apr. 2025, pp. 1–5. [Online]. Available: <https://ieeexplore.ieee.org/document/10890134/>
- [10] V. Caravani, R. De Cesaris, and P. Meriardo, "Assessing and comparing document OCR systems in the era of Large Language Models," *Information Processing & Management*, vol. 64, no. 1, p. 105047, Jan. 2027. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S0306457326004383>
- [11] B. P. Chacko, V. R. Vimal Krishnan, G. Raju, and P. B. Anto, "Handwritten character recognition using wavelet energy and extreme learning machine," *International Journal of Machine Learning and Cybernetics*, vol. 3, no. 2, pp. 149–161, 2012.
- [12] N. T. Ly, C. T. Nguyen, and M. Nakagawa, "Training an End-to-End Model for Offline Handwritten Japanese Text Recognition by Generated Synthetic Patterns," in *2018 16th International Conference on Frontiers in Handwriting Recognition (ICFHR)*. Niagara Falls, NY, USA: IEEE, Aug. 2018, pp. 74–79. [Online]. Available: <https://ieeexplore.ieee.org/document/8563229/>
- [13] I. E. H. Yen, X. Huang, K. Zhong, P. Ravikumar, and I. S. Dhillon, "Pd-sparse: A primal and dual sparse approach to extreme multiclass and multilabel classification," in *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, ser. JMLR: W&CP, vol. 48, 2016.
- [14] K. O. Mohammed Aarif and S. Poruran, "Ocr-nets: Variants of pre-trained cnn for urdu handwritten character recognition via transfer learning," in *Procedia Computer Science (Tercera Conferencia Internacional sobre Computing and Network Communications, CoCoNet'19)*, vol. 171, 2020, pp. 2294–2301, acceso abierto bajo licencia CC BY-NC-ND.
- [15] K. Alomar, H. I. Aysel, and X. Cai, "Data augmentation in classification and segmentation: A survey and new strategies," *Journal of Imaging*, vol. 9, no. 2, p. 46, 2023.
- [16] S. Qi, A. Wang, and D. Baiyila, "Pr2 model: An extended framework for mongolian ocr pre-trained models with prompt tuning in internet of things," *Alexandria Engineering Journal*, 2025, artículo en prensa.

TABLE I
COMPARACIÓN DE TRABAJOS RELACIONADOS

Referencia	Año	Técnica	Dataset	Métrica	Resultado	Limitación
[9]	2025	Data expansion + augmentación balanceada (SmartExp, 2:1, aug. débil)	IAM, CVL, GW	WAR / NED	IAM: +5.6% WAR, +2.7% NED; CVL: +14.8% WAR, +8.4% NED; GW: +14.9% WAR, +6.5% NED (CRNN)	Depende de la calidad del generador HTG
[12]	2018	DCRN end-to-end + distorsión elástica local/global sintética	TUAT Kondate	Acc. carácter	+1.7%	Requiere patrones de caracteres reales previos
[2]	2022	Generación controlable estilo+contenido	Propio, HTR <i>online</i>	CER	-66%	Es <i>online</i> (trazo), no offline
[6]	2022	Few-shot + pseudo-etiquetado progresivo	Manuscritos cifrados / rúnicos (Borg, Copiale, Codex Ruicus)	SER	Borg: 0.24, Copiale: 0.15, Runicus: 0.09 (similares al manual)	Decae con símbolos muy solapados/conectados
[3]	2015	CNN simple, sin extracción manual de features	Bangla propio (20 mil caracteres, 50 clases)	Accuracy	85.96%	Inferior a métodos con selección de características (95.84%)
[10]	2027	Benchmark OCR vs. LLM multimodal (16 sistemas, 4 familias)	SROIE, FUNSD, IAM, FOX	CA, WA, NED, FCA	OCR comercial (más estable), LLM (manuscritos), modelos especializados (mejor eficiencia), open-source (rentable)	No aborda multiclase a nivel de carácter aislado
[1]	2026	Survey HTR	Múltiples (revisión)	CER / WER	N/A	Excluye el nivel de carácter aislado (a propósito)
[4]	2019	Marco teórico clasificación extrema (multi-label/multiclase)	Múltiples dominios	N/A	N/A	Métodos estándar (OvR/OvO) intratables a esta escala
[13]	2016	Margen máximo + penalización ℓ_1 , FC-BCFW (primal/dual sparse)	Benchmarks multiclass/multilabel	Accuracy	Supera a métodos previos de clasificación extrema	Supuestos lineales; no apto para píxeles de imágenes
[5]	2024	CNN script-independent, transfer learning parcial de VGG16, 2 fases	40 datasets, 14 idiomas	Accuracy	Hasta +11%; 26 benchmarks; ~99% en época 1	2ª fase costosa; decae con conjuntos de caracteres muy grandes
[14]	2020	Variante AlexNet/GoogleNet + fine-tuning; dataset con fuentes	IFHCDB (Urdu) + fuentes propias	Tasa de éxito	de 96.3% / 94.7%	Depende del n. de imágenes, resolución y pesos de la red
[15]	2023	Survey de augmentación + RLR (rotación local aleatoria)	MNIST y segmentación	Accuracy	RLR $\geq$ rotación tradicional	La rotación global tradicional sufre bordes irregulares
[11]	2012	Wavelet energy feature + extreme learning machine	Malayalam propio (9K caract., 30 clases, 300 personas)	Accuracy	95.59%	Descriptor geométrico manual; decae con escritura inclinada
[16]	2025	Mask-RCNN (detección) + prompt tuning + RoBERTa (corrección)	MLWS2021 (mongol, recurso)	Acc. de carácter	91.2%	Inferencia lenta; escenarios de fondo complejos